

Triagem adaptativa de atendimentos

Grupo 4

Um Processo de Decisão de Markov para triagem de chamados,
treinado com PPO e DQN sobre um ambiente Gymnasium próprio.

Sumário

- 01 Problema e modelagem
- 02 Ambiente e agentes
- 03 Protocolo experimental
- 04 Resultados e conclusões

01

Problema e modelagem

Triagem com filas e prioridades distintas

- Uma central recebe chamados em três filas — baixa, média e alta prioridade — com chegadas que variam ao longo do turno.
- O agente decide, a cada passo, atender ou encaminhar, buscando reduzir a espera sem abandonar as filas de menor prioridade.
- Trade-off central: equilibrar produtividade (volume atendido) e prioridade (casos críticos) sob demanda estocástica.

Por que é aprendizagem por reforço

- Decisões sequenciais — uma ação muda a fila atual e as penalidades futuras de espera.
- Chegadas estocásticas, segundo distribuições de Poisson em cada fila.
- Objetivos que competem entre si: produtividade, prioridade e tempo de espera.
- Recompensa atrasada — uma fila mantida em espera acumula penalidade crescente.
- Risco de encerramento do episódio por sobrecarga prolongada.

Modelagem como MDP $\langle S, A, T, R, \gamma \rangle$

Estado

Vetor de 9 posições: chamados e espera por fila, capacidade nominal/usada e o passo do episódio.

Recompensa

Duas funções treinadas: produtividade e prioridade — em escalas diferentes, não comparáveis diretamente.

Ações

Discrete(4): duas heurísticas de atendimento e dois encaminhamentos (filas 0 e 1).

Episódios

Turnos de até 100 passos, $\gamma = 0,99$; também encerram por sobrecarga prolongada das três filas.

Estado: o que o agente observa

- q_0, q_1, q_2 — quantidade de chamados em cada fila (até 50 por fila).
- w_0, w_1, w_2 — contador de espera associado a cada fila.
- C, C_u — capacidade nominal total e capacidade em uso.
- t — passo do episódio (0 a 100).

Ações: Discrete(4)

AÇÃO	OPERAÇÃO
0	Atender a fila não vazia de maior prioridade
1	Atender a fila mais longa
2	Encaminhar um chamado da fila 0
3	Encaminhar um chamado da fila 1

Ações inválidas (fila vazia) custam 0,3; capacidade bloqueada custa 0,5; a fila 2 não tem encaminhamento próprio.

Duas funções de recompensa

Produtividade

+1,0 por atendimento; $-0,1 \times (\text{espera} - 3)$ por fila acima do limiar; penalidades de ação sem efeito e de descarte (2,0 por chamado perdido).

Prioridade

Ganho e penalidade de espera ponderados pelo peso da fila (1, 2 ou 3); encaminhar custa 0,5 e não recebe o bônus de atendimento.

02

Ambiente e agentes

Ambiente Gymnasium e baselines

- Classe TriagemEnv, derivada de gymnasium.Env, registrada como TriagemAdaptativa-v0.
- Interface completa: reset(), step(), render(), observation_space, action_space.
- 91 testes do ambiente e das baselines, mais 9 testes de análise — todos passando; Ruff sem erros.

BASELINE	REGRA
Aleatória	sorteia ação uniforme
Prioridade fixa	sempre a ação 0
Fila mais longa	sempre a ação 1

Agentes: PPO e DQN (Stable-Baselines3)

PPO — MlpPolicy	
learning_rate	0,0003
n_steps	2.048
batch_size	64
n_epochs	10
gamma	0,99
gae_lambda	0,95
clip_range	0,2
ent_coef	0,01

DQN — MlpPolicy	
learning_rate	0,001
buffer_size	50.000
batch_size	32
gamma	0,99
exploration_fraction	0,1
exploration_final_eps	0,02
train_freq	4

03

Protocolo experimental

Três configurações, cinco sementes


CONFIG.	ALGORITMO	RECOMPENSA
A	PPO	produtividade
B	PPO	prioridade
C	DQN	produtividade

- Sementes 42, 123, 256, 789 e 1024 × 3 configurações = 15 treinos, 200.000 passos cada.
- EvalCallback a cada 10.000 passos, dez episódios determinísticos.
- Avaliação final: 100 episódios por método, com a recompensa de produtividade.
- Seed surpresa 999: 100 episódios de uma coorte não vista no treino.

04

Resultados e conclusões

Curvas de aprendizado



Reward médio de avaliação por checkpoint, média entre 5 seeds. A Configuração B usa a recompensa de prioridade — escala não comparável às demais.

Agentes superaram as três baselines



Reward médio por episódio (100 episódios, 5 seeds). Barras maiores = pior desempenho. Config A tem o maior reward e o menor custo médio (159,06/episódio).

Atendimento médio por fila



Chamados resolvidos por episódio, média entre 5 seeds. B e C reproduzem a distribuição das baselines de prioridade fixa; A é ligeiramente mais equilibrado entre filas.

Generalização na seed surpresa (999)

CONFIG.	REWARD REFERÊNCIA	REWARD SEED 999	QUEDA
A	-78,67	-84,17	7,0% — moderada
B	-136,28	-158,10	16,0% — severa
C	-112,65	-127,25	13,0% — moderada

Coorte de 100 episódios não vista no treino. Queda classificada como boa (até 5%), moderada (5–15%) ou severa (acima de 15%).

Episódios de sucesso e falha — Config. A

GRUPO	SEED	REWARD	SAÍDAS / CHEGADAS	AÇÃO DOMINANTE
Sucesso	10025	58,8	83 / 85	prioridade, 98%
Sucesso	10037	53,0	85 / 87	prioridade, 96%
Sucesso	10002	49,4	83 / 89	prioridade, 97%
Falha	10073	-479,1	99 / 121	prioridade, 65%
Falha	10069	-411,2	99 / 132	prioridade, 70%
Falha	10055	-405,2	97 / 124	prioridade, 87%

Amostra de 100 episódios (seed 123): sucessos recebem 85–89 chegadas, falhas recebem 121–132 — o agente não acompanha o volume e as filas acumulam espera.

Limitações

- Capacidade nominal sem efeito persistente: o ambiente libera a vaga no mesmo passo em que atende.
- Espera agregada por fila: o contador mede permanência contínua, não a idade individual de cada chamado.
- `total_served` inclui encaminhamentos — a taxa de sucesso não separa atendimento local de encaminhamento.
- Espaço de ações: a fila 2, mais crítica, não tem ação própria de encaminhamento.
- Sem teste de significância entre configurações próximas, como B e a baseline de prioridade fixa.

Conclusão

- Configuração A (PPO + produtividade) teve o melhor reward final e a menor queda na seed surpresa (7,0%).
- Configuração B convergiu para a política de prioridade fixa — diferença de 0,91 ponto, dentro do desvio entre seeds.
- Configuração C (DQN) ficou em segundo lugar geral, com maior variância entre seeds.
- Resultados válidos dentro da dinâmica implementada; as próximas versões devem corrigir as limitações antes de comparar novos números com os atuais.

Obrigado

Perguntas e demonstração ao vivo do ambiente e dos agentes treinados.