

Triagem adaptativa de atendimentos

Um Processo de Decisão de Markov para triagem de chamados com filas, prioridades e chegadas estocásticas.

Sumário

01 Problema e modelagem

02 Ambiente e agentes

03 Protocolo experimental

04 **Resultados, limites e conclusão**

01

Problema e modelagem

Triagem com filas e prioridades distintas

- Um centro recebe chamados em três filas: baixa, média e alta prioridade.
- O agente escolhe a regra de atendimento ou encaminha um chamado.
- Chegadas Poisson mudam a carga; espera, descarte e encaminhamento geram custo.
- O objetivo operacional combina volume atendido e proteção dos casos críticos.

A decisão atual afeta o custo futuro

- Atender uma fila reduz sua carga, mas deixa as outras acumularem espera.
- A demanda é estocástica; uma regra fixa não antecipa todas as sequências.
- O reward soma ganhos imediatos e penalidades que crescem ao longo do turno.
- O episódio termina em 100 passos ou após sobrecarga prolongada.

O ambiente forma um MDP $\langle S, A, T, R, \gamma \rangle$

Estado

Filas, espera, capacidade nominal, uso e passo.

Ações

Duas regras de atendimento e dois encaminhamentos.

Transições

Ação, chegadas Poisson, espera, custo e término.

Desconto

$\gamma = 0,99$ para considerar consequências futuras.

O agente observa nove valores

$$s_t = [q_0, q_1, q_2, w_0, w_1, w_2, C, C_u, t]$$

- $q_0 \dots q_2$: quantidade de chamados em cada fila.
- $w_0 \dots w_2$: permanência contínua da fila em estado não vazio.
- C e C_u : capacidade nominal e capacidade em uso.
- t : passo atual do episódio, de 0 a 100.

O agente escolhe entre quatro ações

- 0 Atender pela maior prioridade

- 1 Atender a fila mais longa

- 2 Encaminhar um chamado da fila 0

- 3 Encaminhar um chamado da fila 1

A política atua como seletora de heurísticas. Ela não escolhe diretamente uma fila para atendimento.

Duas recompensas orientam comportamentos diferentes

Produtividade

- +1 por atendimento local
- espera acima do limiar
- descarte, encaminhamento e ação sem efeito

Prioridade

- +peso da fila atendida
- espera ponderada pela prioridade
- os mesmos custos operacionais

02

Ambiente e agentes

Gymnasium, três baselines e métricas rastreáveis

- TriagemEnv implementa `reset()`, `step()`, `render()` e espaços Gymnasium.
- Baselines: aleatória, prioridade fixa e fila mais longa.
- O modo human exibe filas, esperas e capacidade no terminal.
- O info separa `total_resolved`, `total_referred` e término por sobrecarga.

Compatibilidade preservada: `total_served` continua contando todas as saídas.

PPO e DQN usam políticas MLP

PPO · MlpPolicy

learning_rate	3e-4
n_steps	2.048
batch_size	64
n_epochs	10
gamma	0,99
gae_lambda	0,95
clip_range	0,2
ent_coef	0,01

DQN · MlpPolicy

learning_rate	1e-3
buffer_size	50.000
batch_size	32
gamma	0,99
exploration_fraction	0,1
final_eps	0,02
train_freq	4

03

Protocolo experimental

Três configurações, cinco sementes


CONFIG.	AGENTE	RECOMPENSA
A	PPO	produtividade
B	PPO	prioridade
C	DQN	produtividade

- Seeds 42, 123, 256, 789 e 1024.
- 200.000 passos por treino; 15 modelos.
- 100 episódios na avaliação final.
- Seed surpresa 999, fora do treino.

04


Resultados e conclusões

As três configurações melhoram durante o treino



A recompensa de prioridade usa outra escala; a comparação direta ocorre na avaliação comum.

PPO produtividade obteve o maior reward médio



Configuração A


reward -78,67
custo médio 159,06
taxa de saída 91,76%

A diferença B × prioridade fixa é menor que a dispersão entre sementes.

A distribuição por fila revela a política aprendida

Chamados resolvidos por fila — agentes vs baselines

Média por episódio entre 5 seeds; barras de erro = ± 1 desvio padrão entre seeds



A configuração B coincide com a prioridade fixa nas três filas.

O PPO aprendeu uma regra coerente com a recompensa, mas sem vantagem mensurável sobre a heurística equivalente.

No gráfico legado, 'resolvidos' significa saídas: atendimento local + encaminhamento.

A carga separa os melhores e os piores episódios

3 melhores

85–89 chegadas
83–85 saídas
reward de 49,4 a 58,8
prioridade em 96%–98% das ações

3 piores

121–132 chegadas
97–99 saídas
reward de -405,2 a -479,1
espera máxima de até 79 passos

A associação não prova causalidade: os episódios ruins também receberam mais chamados.

A seed surpresa expôs sensibilidades diferentes

CONFIGURAÇÃO	REWARD	QUEDA	LEITURA
A · PPO produtividade	-84,17	7,0%	moderada
B · PPO prioridade	-158,10	16,0%	severa
C · DQN produtividade	-127,25	13,0%	moderada

Uma seed surpresa testa uma coorte não vista; ela não demonstra generalização universal.

A equipe aplicou ajustes sem mudar o MDP

Implementado agora

- Contadores de resolução e encaminhamento.
- Indicador de término por sobrecarga.
- README, relatório e slides alinhados.

Preservado para não invalidar os modelos

- Capacidade é liberada no mesmo passo.
- Espera é agregada por fila.
- Ações de atendimento são heurísticas.

Os resultados valem para a dinâmica implementada

- PPO com produtividade apresentou o maior reward e o menor custo.
- DQN ficou em segundo lugar; PPO prioridade reproduziu a baseline fixa.
- Os resultados publicados medem saídas, pois incluem encaminhamentos.
- Os novos contadores melhoram a leitura sem exigir novo treino.

Próximo experimento: duração de serviço, capacidade persistente e ações diretas por fila.

Perguntas?

Triagem adaptativa de atendimentos · Grupo 4

github.com/RafaelQSantos-RQS/TriagemAdaptativaDeAtendimentos